MENTRIX / TAFlow · AI ENGINEERING & RESEARCH HANDOFF · 04 NOV 2026

تقرير المشروع الشامل من البداية إلى Sprint 06

تاريخ الـGrading والـOCR والـChatbot والحضور، مقارنة النماذج والقواعد، تنفيذ الـHandwriting OCR الجديد، الاختبارات التي نجحت، وما لم يتم التحقق منه علميًا حتى الآن.

نسخة للتيم والمعيدة — مبنية على ملفات المشروع المرفوعة ونتائج البحث الموجودة بداخله، مع فصل صريح بين الأدلة القديمة والعمل الجديد.

81/81	4	646	0
اختبار برمجي ناجح في حزمة التسليم الحالية	OCR Pipelines مُعدة للمقارنة المباشرة	صفًا في ASAG المرفقة (نصوص، مش صور خط يد)	قياسات OCR جديدة حقيقية على IAM في هذا التسليم

القرار العلمي الأهم: تم تنفيذ وتجريب الكود والـAPI بموديل OCR وهمي لأغراض الاختبار على ورقة مطبوعة Synthetic، ولكن **لم تُحمّل IAM أو أوزان TrOCR ولم يُشغّل Inference جديد على خط يد بشري داخل هذه البيئة.** أرقام CER/WER العلمية الجديدة = غير متاحة؛ ممنوع تحويل نجاح اختبارات البرمجيات إلى Accuracy للموديل.

1 · الملخص التنفيذي

منصة **MENTRIX** هي Local Research Pilot لمساعدة المعيدة في السكاشن: إدارة الطلاب والسكاشن، QR Attendance مع Student ID + PIN، بنك أسئلة ورُبركات معتمدة بشكل تجريبي، مسودات OCR للأوراق، تصحيح محافظ لبعض أنواع الأسئلة، مراجعة الحالات الملتبسة، نشر درجات على دفعة، Chatbot يعتمد على بيانات SQLite المسجلة، ولوحة تجارب بحثية.

الخطوة الجديدة Sprint 06 تفصل بصورة واضحة بين **Detection → Recognition → Question Mapping → Human Verification → Grading → Publication**. استُخدمت وحدات برمجية مستقلة تسمح بقياس فشل كل مرحلة من غير ما تحمّلي مسؤولية الخطأ على مرحلة مختلفة.

Full handwritten answer sheet → Line detection → TrOCR line recognition → Q1 / Q2 segmentation → Staff-verified transcript → Safe rules + TA review → Batch publish

2 · تاريخ المشروع من البداية، خطوة خطوة

المرحلة التأسيسية — Scope & Architecture

تم تعريف MENTRIX/TAFlow ومن يملك كل جزء: AI مسؤول عن OCR وتجارب التصحيح، Backend عن قاعدة البيانات وصلاحياتها والنشر، Frontend عن واجهة المعيدة. تحديد أنواع الأسئلة: **MCQ**، **Short Answer (1–3 كلمات)**، **Math**، **Essay**، مع استبعاد التصحيح الآلي العام للإجابات العربية في V1. وثائق الأصل في `docs/PHASE_1_AI_SCOPE_ARCHITECTURE_AR.md`.

Prototype Grading — Strict → V1 → V2

Strict يقارن الإجابة حرفيًا، V1 أضاف قواعد لكل نوع مع Normalization وAliases وSymPy في بعض حالات Math، ثم V2 أصبح أكثر تحفظًا في المختصرات والأخطاء الإملائية والالتباس وقيود الـDomain. V2 **نسخة قواعد وليست موديل AI مدرّب**، وEssay تظل تحت مراجعة بشرية. الاختبارات التوضيحية التاريخية 123 حالة صُممت لمعايرة القواعد، فلا تُعتبر اختبارًا مستقلًا.

بدايات E01 Baseline — OCR & سطور بشرية محدودة

الكود السابق يدعم TrOCR-base-handwritten على Crops لسطور، واقتراح فواصل سطور ومقارنة Original RGB وAutocontrast وPadding؛ وتوجد إشارة تاريخية في README إلى WER حوالي **57.69%** على 7 إجابات وإلى رقم تشخيصي **50.09%** بعد تعديل التقسيم على نفس البيانات. العدد الصغير والتعديل في نفس البيانات يعنيان أن النتيجة لا تثبت تعميمًا أو اختيارًا علميًا لفائز. صور وخطوط جديدة وGround Truth مستقل لم تكن مرفقة.

Sprint 01–02 — تنظيم البحث والتكرار

جرد مصادر البيانات والتجارب القديمة، Scripts لتقييم OCR مع CER/WER مشروطة بنص مرجعي مؤكد، تجهيز ASAG/ASAP، وتطوير فحوصات تجارب قابلة لإعادة التشغيل على بيانات مكتوبة ونتائج مرجعية/سجلات تشغيل. حافظنا على الأكواد والـReports الأصلية داخل الحزمة بدل إعادة تسمية نتائجهما كأنها جديدة.

Sprint 03 — ASAG Benchmark

ملف ASAG المرفق: **646** إجابة/صف، منها **607** إجابة بشرية غير فارغة و**39** فارغة، على **17** سؤالًا؛ الإجابات في المتوسط قرابة **57.73** كلمة للغير فارغ. تقسيم Seed 42؛ **Validation 125** و**Test 129**، وسبع طرق Baseline. هذه Dataset **نصية طويلة نسبيًا**، وليست بيانات OCR Handwriting ولا تطابق 1–3 Short Answer كلمات.

Sprint 04 — تحليل الأخطاء والنماذج الدلالية

إنشاء Error Analysis للحالات الخطيرة (منح 2/2 رغم درجة بشرية أقل)، وتجهيز MiniLM/NLI وخطوات تشغيلهما. النتائج الفعلية الجديدة لهذين النموذجين **غير موجودة** في المشروع المرفوع؛ لا يجوز نسب MAE أو QWK جديدة لهما. Rubric+NLI على ASAG لم يُنفذ لغياب Rubrics حقيقية معتمدة لكل سؤال.

Sprint 05 — Audit & Research Gate

إعادة إنتاج توقعات Test لـ7 Baselines على نفس Frozen Split، وتحليل 54 خطأ في الاختيار المبني على Validation، ومنها **26** حالة منح درجة كاملة خطر. نتيجة الـSafety Gate: **DISABLED_NO_VALIDATED_RULE**، أي **0/129** حالة سُمح بالاعتماد التلقائي لها بحثيًا؛ وهذا لا يساوي أن الـModel صفر Accuracy، بل أن سياسة الثقة المطلوبة لم تجتز شرط السلامة.

MENTRIX Integrated V1 — موقع موحّد

إضافة SQLite و30 طالبًا وهميًا/سكشن، Student ID+PIN، QR يتغير كل 30 ثانية، Random Checks، رفع PDF/صور ورقة كاملة، Review ثم Grading حسب بنك أسئلة، نشر Chatbot، CSV exports، Batch لاستعلام حضور ونتائج فعلية من البيانات المخزنة. **ملفات SQLite تجريبية ولا تصلح كنظام آمن منشور على الإنترنت.**

Sprint 06 — هذا التسليم (4 نوفمبر 2026)

تحضير IAM importer يضمن Writer IDs، أربع Pipelines متطابقة العينات، اختيار على Validation وتثبيت Test، Script لصفحة كاملة، Evaluation مستقل للـRoutes & UI، OCR/Question segmentation/Grading diagnostic جديدة، وحواجز تمنع اعتماد مسودة OCR كإجابة بشرية متحقق منها. جرى تنفيذ **81 اختبارًا برمجيًا** ناجحًا تشمل **12 اختبارًا جديدًا** لـ06 Sprint؛ لا تتضمن inference حقيقي لخط يد.

3 · النتائج الموثقة فعلًا من ASAG (سجلات Sprint 05 المجمدة)

الجدول التالي من ملف `research/sprint5/results/s05_reproducibility_and_gate.json`، ولم نعيد تشغيل تدريب هذه الطرق في Sprint 06.
MAE أقل أفضل؛ **QWK** و**Exact** **أعلى أفضل**. في كل صف Test n=129.

Method	MAE ↓	Exact ↑	QWK ↑	Full-credit risk
mean	0.426	57.4%	0.340	16
tfidf_word_ridge	0.426	57.4%	0.343	18
tfidf_char_ridge	0.450	55.8%	0.286	21
token_overlap_knn	0.357	65.1%	0.434	18
tfidf_word_knn	0.434	58.1%	0.311	25
tfidf_char_knn	0.426	58.9%	0.338	25
reference_jaccard_ridge	0.442	55.8%	0.317	18

فهم الأرقام: token_overlap_knn له أقل MAE بين الأساليب السبعة في هذا الجدول (**0.35659**)، لكنه أنتج أيضًا **18** حالة منح درجة كاملة خطر، ولذلك لا يبرر Auto-Publish. الـMethod المختار تاريخيًا وفق Validation حقق Test MAE=**0.42636**، Exact=**58.1%**، و**26** Full-credit risky errors. لا نختار موديلًا للدرجات رسميًا من هذه النتائج وحدها.

4 · ماذا نفّذ Sprint 06 بالتحديد؟

المكوّن	ما يعمل بالكود	دليل التشغيل الحالي
IAM importer	قراءة images + transcriptions من lines.txt وXML writer-id وتطبيق split lists رسمية ومنع writer leakage.	**اختبار بيانات وهمية ناجح؛ IAM أصلية غير محملة**
Line OCR Benchmark	تعرف السطور بـTrOCR، حساب CER وWER micro-averaged، التتبع بالـSHA256، مقارنة Paired.	**الكود جاهز؛ النموذج الحقيقي لم يُشغَّل**
Selection protocol	اختيار Validation قبل Test، تشغيل الفائز فقط في Test، والحماية من تعديل Manifest.	**فحوصات برمجية؛ لا Winner حقيقي بعد**
Full-sheet module	PDF/Image → اقتراح سطور → Mapping → OCR عبر Q1.. أو Manual Regions → Draft + Diagnostics.	**اختبار end-to-end اصطناعي بـOCR بديل؛ لم يُختبر بخط يد بشري**
Three-way Evaluation	OCR CER/WER؛ Question-ID Recall/Precision وRegion IoU عند وجود GT؛ أخطاء الدرجات إذا وُجدت درجات بشرية مستقلة.	**حسابات/قواعد مختبرة، بلا GT حقيقية بعد**
MENTRIX UI + API	زر OCR Handwriting على الورقة الموجودة، اختيار Pipeline، منطق تحقق ومنع نشر تلقائي، حفظ Draft.	**اختبارات API مع Fake recognizer ناجحة**

الـ4 Pipelines المرشحة — بدون اختراع Winner

ID	TrOCR	Preprocess	الحالة
E01_base_rgb	microsoft/trocr-base-handwritten	Original RGB (Frozen Baseline)	جاهز لإعادة التقييم
E02_base_autocontrast	نفس Base	Autocontrast خفيف	لا نفترض أنه أفضل
E03_small_rgb	microsoft/trocr-small-handwritten	Original RGB	بديل أصغر للـCPU
E04_base_padded	نفس Base	Padding + Conditional Upscaling	مقارنة مش ضمان تحسن

نقطة مهمة: TrOCR يتعرف على **سطر صورة**، وليس على الورقة كلها مباشرة. الـLine detection وتقسيم الأسئلة مشاكل مستقلة، واحتمال أن يخطئ Tesseract أو الـProjection فيها لا يعني أن TrOCR قرأ السطر خطأ. كذلك النماذج Handwritten المعلنة Fine-tuned على IAM نفسها، فتجربة IAM In-domain فقط، ويجب إجراء اختبار بشري مستقل على أوراق كويز من البيئة المستهدفة.

5 · كيف نقيس الاختبار الحقيقي للورقة الكاملة؟

المرحلة	الـGround Truth المطلوب	Metric	هل اتقاس حقيقيًا الآن؟
Reading Handwriting	Transcription لكل سطر أو لكل سؤال، كتبه إنسان مستقل عن OCR	CER / WER / Exact line rate	لا
Question separation	Question ID مقابل كل سطر، وBounding Boxes يحددها المراجع	ID Precision/Recall + Region IoU@0.5	لا
Grading	Mark نهائي من TA + Question Bank/ Rubric معتمد	Agreement، Wrong auto-grade count، Coverage؛ ويمكن MAE بعد اكتمال البيانات	لا
End-to-end	الورقة الأصلية مع جميع annotations السابقة	Success by question + TA escalation rate	لا

> لا يمكن حساب «دقة فصل الأسئلة» من مجرد أن الـOCR خرج نصًا. ولا يمكن حساب «دقة التصحيح» من مقارنة OCR بنفس النص الذي ولد منه مفتاح الإجابة. من الضروري وجود annotations مستقلة وحماية من Data Leakage.

6 · الاختبارات البرمجية: ما الذي نجح، وما الذي لم يُختبر؟

الأمر: `python -m pytest -q` على جذر MENTRIX. **النتيجة: 81 passed** في بيئة التسليم الحالية؛ كانت الاختبارات الموروثة **69 passed** قبل إضافات Sprint 06، وأُضيفت **12** اختبارات.

الاختبارات الجديدة شملت Metrics، اكتشاف سطور ورقة Manual Regions، Question labels، Printed Synthetic ورفض الإحداثيات الخاطئة، غياب سؤال، Writer leakage، مقارنة Paired بنفس الصفوف، IAM XML importer، وربط FastAPI من رفع الورقة إلى OCR Draft ثم تأكيد النص والتصحيح مع منع تصحيح Essay آليًا.

مستوى الثقة: نجاح وظائف الكود محليًا، وليس نجاح OCR Model. اختبار الواجهة ببراوزر حقيقي على جهاز Windows مختلف، وانقطاع الإنترنت أثناء تحميل موديل، وRAM/CPU latency، ودقة الخط اليدوي الفعلي ما زالت غير مختبرة هنا.

7 · خطوات التشغيل العملية على Windows

1. فكّي ملف ZIP كاملًا، ثم افتحي `MENTRIX/START_MENTRIX_HERE.bat`. التطبيق يُشغّل على Localhost برمز TA/Admin، ولا يحتاج تثبيت موديلات OCR لفتح الموقع.
2. للتأكد من البرمجة فقط: `RUN_SPRINT06_TESTS.bat`.
3. لاستخدام قراءة الخط اليدوي: `INSTALL_SPRINT06_OCR.bat` أول مرة، مع إنترنت لتنزيل أوزان TrOCR، ثم افتحي Quiz Grading وارفعي PDF أو PNG/JPG واختاري الورقة واضغطي **Read handwriting with TrOCR**.
4. لنتائج IAM: سجّلي رسميًا وخذي line images وXML وsplit IDs، ثم استخدمي `research/sprint6/prepare_iam.py` لتوليد Manifest.
5. شغّلي `RUN_SPRINT06_CPU_SMOKE.bat` للـDiagnostic المحدود، ثم `RUN_SPRINT06_VALIDATION.bat` للأربع Pipelines، ثم `RUN_SPRINT06_FROZEN_TEST.bat` للفائز فقط.
6. أحضري ورقة كاملة بخط يد حقيقي مع Transcript وقيم درجات معتمدة مستقلًا؛ شغّلي `research/sprint6/full_sheet.py` واحفظي JSON النتائج. راجعي Original، ثم TA Verified ثم Review ثم Batch Publish في MENTRIX.

8 · المجلدات والملفات الأهم للتيم

المسار	المحتوى
`research/sprint1..5/`	الأبحاث ونتائج ASAG / ASAG safety gate والمقارنات التاريخية، محفوظة
`research/sprint6/benchmark.py`	Paired CER/WER Benchmark واختيار Validation/Frozen Test
`research/sprint6/prepare_iam.py`	استيراد IAM مع Writer IDs
`research/sprint6/full_sheet.py`	قراءة ورقة كاملة + Segmentation + تقييم مستقل
`handwriting_routes.py`	Endpoints للـTA في التطبيق
`static/workspace.js`	اختيار Pipeline وتشغيل OCR من واجهة Grading
`research/sprint6/tests/test_sprint6.py`	12 اختبارًا هندسيًا جديدًا
`research/sprint6/results/execution_status.json`	الفرق بين ما نُفذ وما لم يُنفذ علميًا
`research/sprint6/README_AR.md`	دليل كامل للتشغيل وتفسير النتائج والقيود

9 · ما المتبقي للوصول لنسخة بحثية مبرهَنة؟

1. **IAM Data & legal use**: تسجيل وتحميل النسخة الرسمية، وإرفاق Dataset source/version/hash بدون نشر صور محمية أو هوية الطلاب.
2. **Real inference**: تشغيل E01–E04 فعليًا وحفظ CER/WER + Error log + الموارد/الزمن؛ اختيار واحد على Validation دون النظر لـTest.
3. **New-writer holdout**: صور خط يد كويز متنوّعة من كتاب جدد، وGround Truth بمراجع مستقل، وتقسيم حسب Writer.
4. **Question-level annotations**: تحديد السؤال/السطر/Bounding Box في ورقة كاملة، وقياس ID mapping وSpatial IoU.
5. **Grading safety**: Rubrics ومفاتيح ودرجة بشرية مستقلة لأسئلة MCQ/Short/Math/Essay، ثم قياس أخطاء درجات النظام وحالات Review على نفس الأوراق.
6. **Production gaps**: هوية حقيقية وصلاحيات، حماية بيانات/HTTPS، تدقيق وتشفير، تشغيل أجهزة الطالب، أداء CPU/GPU وFine-tuning إذا أثبت تحليل الأخطاء حاجته. مشروع الـEssay auto-grader لا يزال معلّقًا.

قرار التسليم للتيم والمعيدة: Sprint 06 **Engineering-ready** مع تكامل قابل للاختبار؛ أما **Research evaluation** فـ**Pending real IAM/handwriting dataset and approved annotations**. لا نعلن Best OCR model أو CER/WER جديدة أو دقة تصحيح بدون تنفيذها وتوثيقها.

10 · المراجع وملاحظات النزاهة

جميع نتائج ASAG أعلاه مأخوذة حرفيًا من JSON داخل الملفات المرفوعة؛ أرقام OCR التاريخية مصدرها README القديم ولا تُعاد تسميتها تجارب جديدة. تاريخ التقرير 2026-11-04. صور IAM وأوزان النماذج ليست مضمنة لأسباب ترخيص/حجم/تحميل. نتيجة 81 passed وُجدت من تشغيل حقيقي لوظائف البرمجيات.

- IAM: fki.tic.heia-fr.ch/databases/iam-handwriting-database — Non-commercial research, registration and citation requested.
- TrOCR Base: huggingface.co/microsoft/trocr-base-handwritten
- TrOCR Small: huggingface.co/microsoft/trocr-small-handwritten
- TrOCR official implementation: microsoft/unilm/trocr.

MENTRIX / TAFlow — local academic research prototype. No official grades or institutional approvals implied.