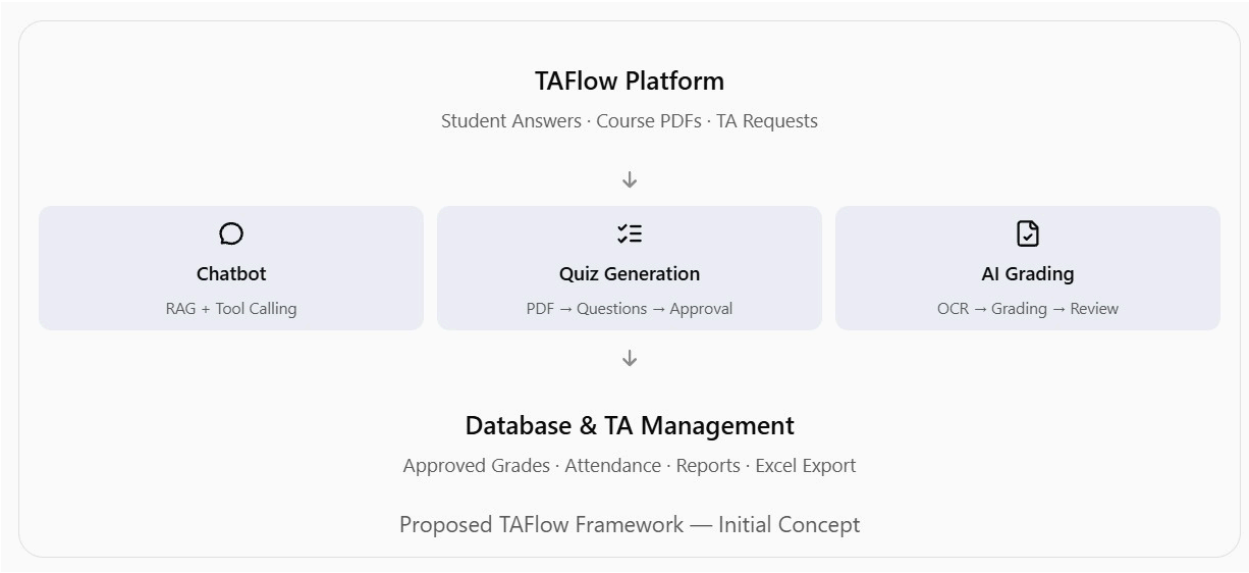


نتائج أول تجربة

QWK	MAE	Model / Method
0.2489	**2.0427**	Token Overlap
0.2431	2.0540	TF-IDF Characters
0.0993	2.3090	TF-IDF Words

ببساطة:
- MAE: أفضل، كل ما يقل. متوسط الفرق بين الدرجة المتوقعة والدرجة المرجعية.
- QWK: أفضل، كل ما يقرب من 1. مقياس اتفاق الدرجات.
- النتيجة: Token Overlap ضعيف عمومًا لكن الأداء في المقياسين دول، الأفضل حاليًا.

نتائج المقارنة بعد إضافة MiniLM

Model	↓ MAE	↑ QWK	إجابات بفارق درجة أو أقل
SBERT MiniLM	**1.7974**	0.2488	28%
Token Overlap	2.0427	**0.2489**	24%
TF-IDF Characters	2.0540	0.2431	26%
TF-IDF Words	2.3090	0.0993	**36%**

1. فين الموديل بيغلط؟

نوع الإجابة	متوسط خطأ MiniLM
Partial	0.60
Correct	1.45
Incorrect	1.77
Paraphrase	1.94
Contradiction	**3.23**

المشكلة الأكبر في Contradictions، يعني الإجابات اللي بتناقض الإجابة الصحيحة.

Question: Why is cache memory used?

Student Answer

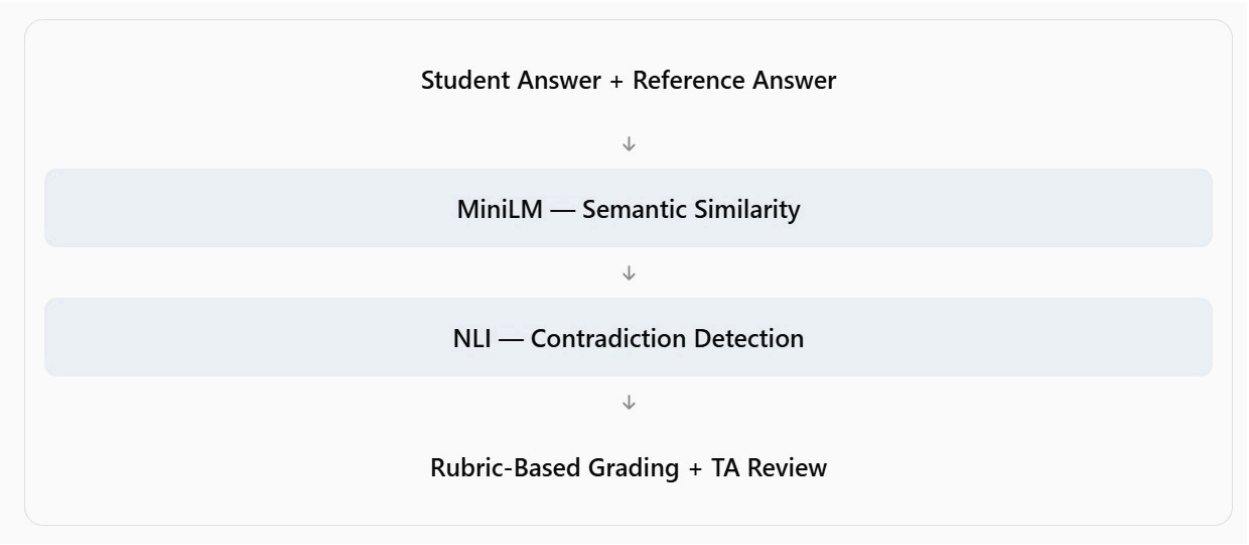
".Cache intentionally increases CPU access latency for frequently used data"

Reference Score	MiniLM Prediction
5 / 0	5 / 4.25

الموديل أعطى درجة مرتفعة لإجابة بتقول إن الـCache بتزود وقت الوصول للذاكرة، بينما الصحيح إنها بتقلله!

وده لأن Semantic Similarity مش بالضرورة Semantic Correctness. التشابه في الكلمات والمعنى العام لا يكفي لاكتشاف التناقضات.
إيه القرار اللي خرجنا بيه؟
مش هنختار MiniLM لوحده لتصحيح الإجابات.

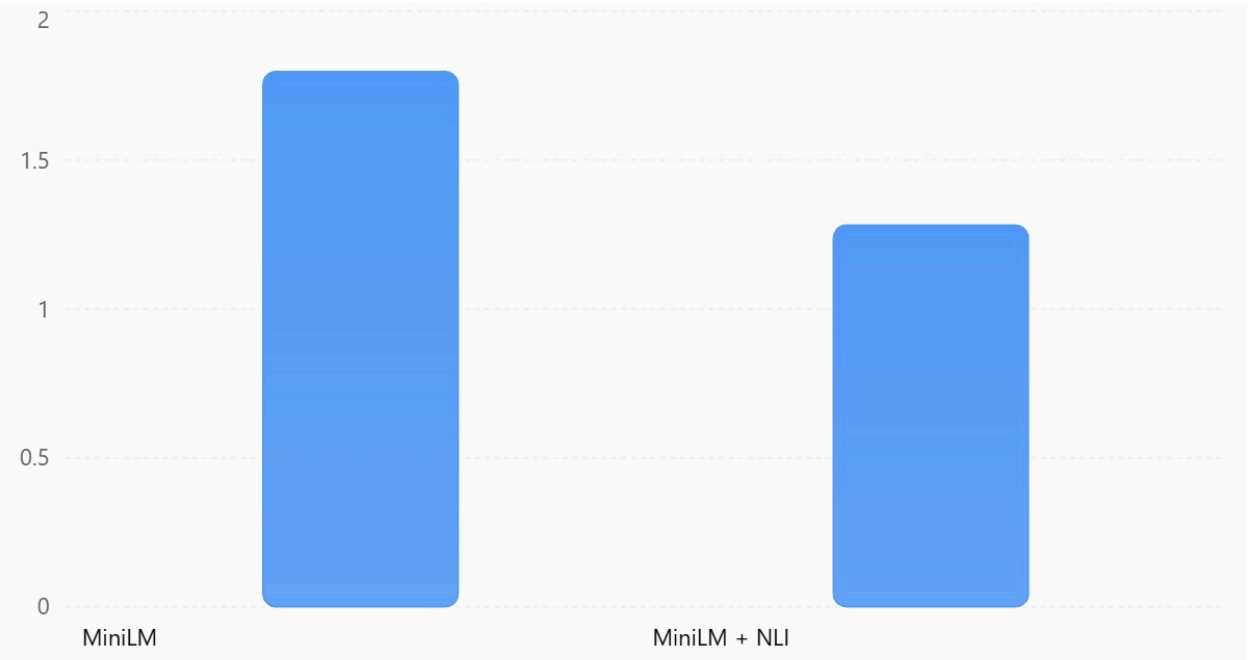
هنختبر تصميم أقوى:



1. مقارنة MiniLM قبل وبعد NLI

Metric	MiniLM	MiniLM + NLI
↓ MAE	1.7974	**1.2814**
↓ RMSE	2.1246	**1.5021**
↑ QWK	0.2488	**0.6513**
↑ Within 1 Point	28%	**56%**

النتائج الأولية بتقول إن إضافة NLI حسّنت أداء التصحيح، وقللت متوسط الخطأ بحوالي 29%.



الأقل أفضل — على 50 إجابة تجريبية

2. لكن هل NLI بيكتشف التناقضات بدقة؟

Recall	Precision
90%	56.25%
اكتشف 9 من 10 تناقضات	9 اكتشافات صحيحة من 16

يعني عندنا:

- 9 تناقضات اكتشفها صح.
- 7 إجابات صنّفها كتناقضات بالخطأ.
- تناقض واحد فشل في اكتشافه.

ودي مشكلة مهمة: لأن الـ7 False Positives ممكن تسبب خصم درجات من إجابات مش متناقضة.

كمان التحسن ده على داتا تجريبية، ولسه محتاجين نختبره على إجابات حقيقية مصححة من المعيد.

إضافة NLI حسّنت نتائج التصحيح التجريبي، لكن اكتشفنا إن المشكلة مش بس في الموديل، كمان في طريقة اتخاذ قرار تعديل الدرجة.

1. تحليل أخطاء NLI

من أصل 50 إجابة، النموذج حدّد 16 إجابة باعتبارها متناقضة وتحتاج مراجعة.

True Positives	False Positives
9	7
تناقضات اكتشفها صح	إجابات اتصنفت كتناقض بالغلط
False Negatives	**True Negatives**
1	33
تناقض لم يتم الإبلاغ عنه	إجابات لم تُصنف خطأً كتناقض

لكن المفاجأة إن الـ7 False Positives مش كلهم نفس نوع الخطأ:

- 6 إجابات Incorrect أصلًا، ودرجتها المرجعية صفر. تصنيفها كتناقض غير دقيق وفق تقسيم الداتا، لكنه ساعد قاعدة تعديل الدرجات في تقليل الخطأ.
- إجابة واحدة Partial، وكانت تستحق 2.5/5، لكن النظام خفّض توقع الدرجة إلى 1/5.

وده يوضح الفرق بين إن النظام يكتشف وجود إجابة غير صحيحة، وبين إنه يعرف نوع الخطأ ويحدد الدرجة المستحقة.

2. أخطر مثال لقيناه

Q02_A03 — Overfitting False Positive

Student Answer

"It performs very well on its training examples."

الإجابة ناقصة، لكنها مش متناقضة مع مفهوم Overfitting.

الدرجة المرجعية	MiniLM	MiniLM + NLI
2.5	1.51	1.00

NLI أعطى احتمال تناقض حوالي 99.5% رغم إن الإجابة صحيحة جزئيًا.

الاستنتاج: مينفعش نخلي NLI يخصم درجات تلقائيًا لمجرد إن احتمال التناقض مرتفع، خصوصًا في الإجابات الجزئية.

التناقض اللي الموديل فوّته

في السؤال Q07_A05 عن الفرق بين Unit Testing وIntegration Testing، إجابة الطالب عكست المفهومين تمامًا.

- الدرجة المرجعية: 0/5
- توقع MiniLM: 3.70/5
- احتمال التناقض في NLI: 61.7%

الموديل رجّح فعلًا تصنيف contradiction، لكن قاعدة الـThreshold ما اعتبرتش الاحتمال كافيًا.

جرّبت تحليل النتائج باستخدام Thresholds مختلفة على نفس البيانات. خفض الحد إلى 60% اكتشف التناقضات العشرة، لكنه رفع عدد الـFalse Positives إلى 8.

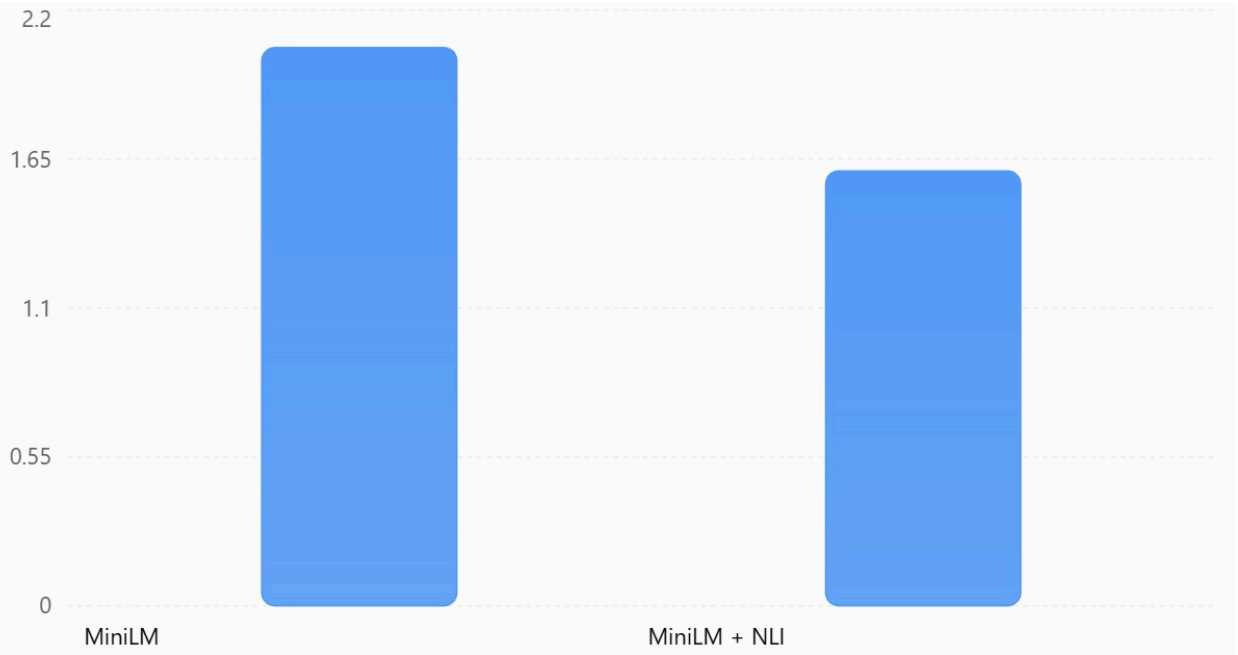
إذن تغيير الـThreshold لوحده مش حل كافي.

نتائج الاختبار الجديد

Model	↓ MAE	↑ QWK
Token Overlap	**1.7821**	**0.3404**
TF-IDF Characters	1.8217	0.3023
TF-IDF Words	1.9839	0.2702
SBERT MiniLM	2.0616	0.2991

1. نتائج MiniLM قبل وبعد NLI

Metric	MiniLM	MiniLM + NLI
↓ MAE	2.0616	**1.6058**
↓ RMSE	2.3157	**1.9098**
↑ QWK	0.2991	**0.4597**
↑ Within 1 Point	20%	**48%**



متوسط خطأ الدرجات MAE — الأقل أفضل

النتيجة: إضافة NLI قللت متوسط خطأ MiniLM بحوالي 22% على الداتا التجريبية الجديدة.

وكمان MiniLM + NLI حقق أقل MAE مقارنة بالطرق الخمس اللي اختبرناها على نفس البيانات.

2. هل NLI اكتشف التناقضات صح؟

Precision	Recall
37.5%	60%
3 اكتشافات صحيحة من 8	اكتشف 3 من 5 تناقضات

وده معناه إن الموديل لسه عنده مشكلتان: صنّف 5 إجابات كتناقضات بالخطأ، وفاته تناقضان حقيقيان وفق الـPilot Labels.

الملاحظ إن إضافة NLI حسّنت متوسط الدرجات، لكن دقة اكتشاف التناقضات نفسها مش كافية للاعتماد عليها في التصحيح التلقائي.

النتيجة الأساسية: MiniLM + NLI حسّن درجات الاختبار التجريبي، لكنه لسه مش قادر يفرق باستمرار بين الإجابة الخاطئة، والإجابة المتناقضة، والإجابة الصحيحة بصياغة مختلفة.

1. الأخطاء السبعة بالتفصيل

الـ5 False Positives

دي إجابات النظام اعتبرها تناقضات، رغم إن تصنيفها المرجعي مش `contradiction`.

Sample ID	نوع الإجابة الحقيقي	احتمال التناقض
Q02_D02	Paraphrase صحيحة	92.49%
Q02_D04	Incorrect	83.46%
Q03_D04	Incorrect	97.36%
Q04_D04	Incorrect	81.87%
Q05_D04	Incorrect	97.67%

أخطر حالة هي `Q02_D02`:

Question: Compare sine waves and square waves.

Student Answer:

The analog waveform is sinusoidal: its value increases and decreases gradually without breaks. The" ".rectangular waveform has sudden transitions between two states and is used for 0/1 digital data

الإجابة صحيحة من حيث المعنى، ودرجتها المرجعية 5/5.

Gold Score	MiniLM	MiniLM + NLI
5/5	3.29	1.00

هنا إضافة NLI زوّدت الخطأ بدل ما تقلله.

والـ4 إجابات الأخرى خاطئة بالفعل، لكن وصفها بالتناقض مش دقيق وفق تصنيفات الـDataset. ده فرق مهم بين Incorrect Answer Detection وContradiction Detection.

الـ2 False Negatives

Sample ID	المشكلة	احتمال التناقض
Q01_D05	عكس مفهوم Continuous وDiscrete Signals	64.79%
Q02_D05	عكس خصائص Sine وSquare Waves	30.38%

الأولى الموديل صنّفها contradiction لكن لم تتجاوز حد اتخاذ القرار، والتانية الموديل صنّفها entailment أصلًا، رغم إن الإجابة بتعكس المفاهيم.

2. هل إضافة NLI حسّنت كل أنواع الإجابات؟

لأ. ودي أهم نتيجة في الـError Analysis.

MAE حسب نوع الإجابة — الأقل أفضل

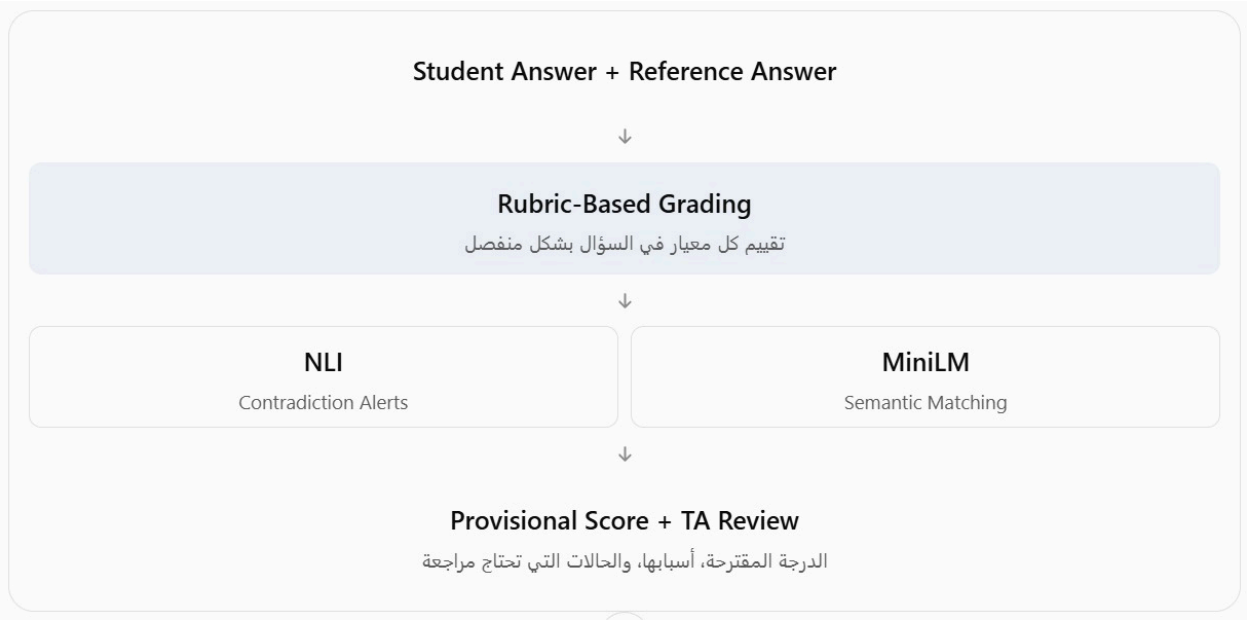
Answer Type	MiniLM	MiniLM + NLI
Correct	0.703	0.703
Paraphrase	**1.829**	2.287
Partial	1.479	1.479
Incorrect	2.962	**1.430**
Contradiction	3.335	**2.130**

يعني الإضافة حسّنت التعامل مع الإجابات الخاطئة والمتناقضة، لكنها أضرّت بإحدى الإجابات الصحيحة المعاد صياغتها.

وكل الأرقام دي على Dataset مصطنعة، مش Human-Graded Test Set.

3. التعديل المقترح على Framework

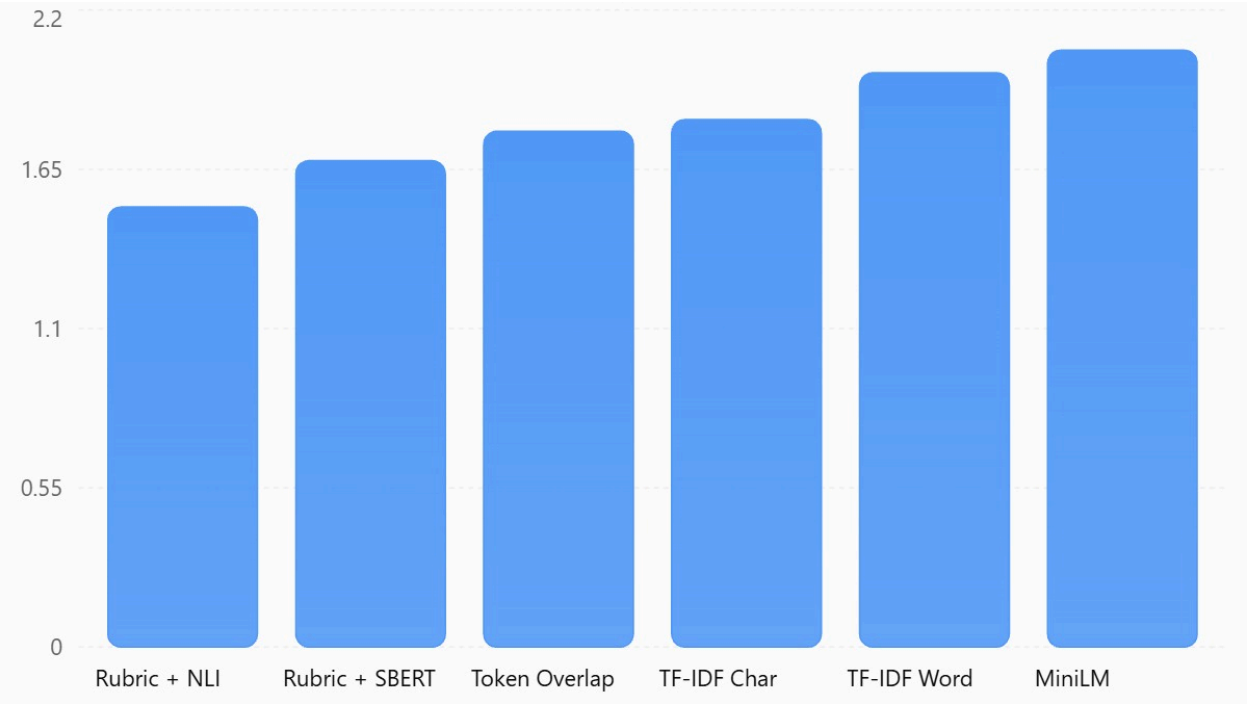
بدل ما نستخدم MiniLM + NLI لإعطاء الدرجة مباشرة، هنجرّب نظام يعتمد على توزيع درجات السؤال حسب الـRubric:



1. نتائج مقارنة الموديلات

اختبرنا 6 طرق على نفس الـ25 إجابة التجريبية.

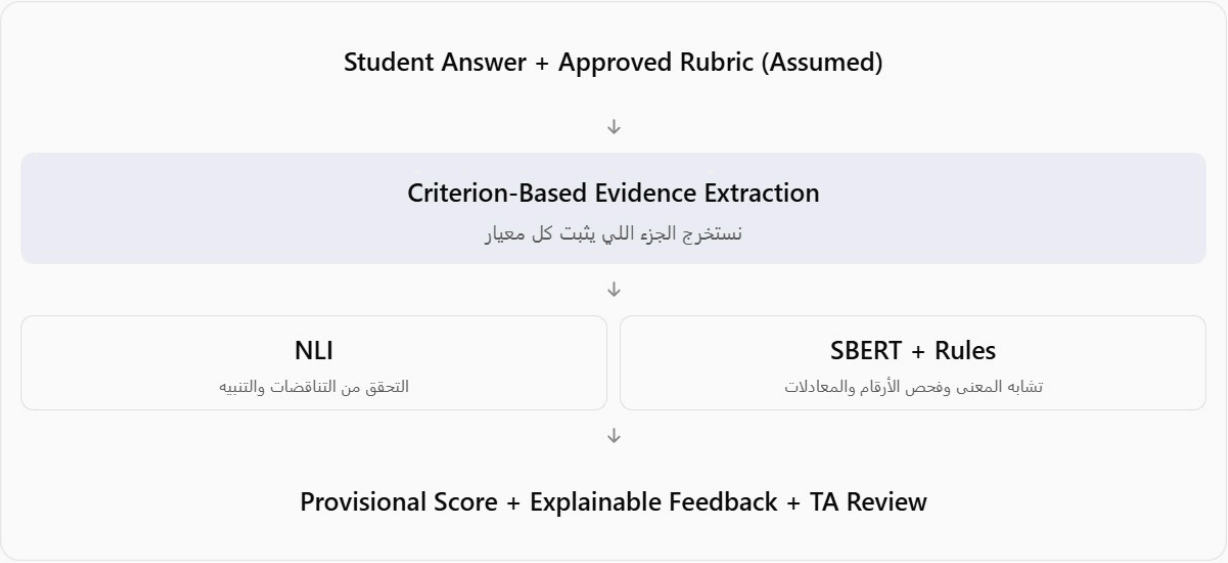
Model / Method	↓ MAE	↑ QWK
Rubric + NLI	**1.5200**	**0.4794**
Rubric + SBERT	1.6800	0.3031
Token Overlap	1.7821	0.3404
TF-IDF Characters	1.8217	0.3023
TF-IDF Words	1.9839	0.2702
SBERT MiniLM	2.0616	0.2991



2. المشكلة الأكبر في دقة التصحيح

متوسط خطأ الدرجات حسب نوع الإجابة — الأقل أفضل

Rubric + NLI	Rubric + SBERT	نوع الإجابة
1.2	**0.6**	Correct
3.8	**3.2**	Paraphrase
1.6	**0.6**	Partial
0.2	1.2	Incorrect
0.8	2.8	Contradiction



4. إيه الفرق بين الطرق السبع؟

Method	بتشتغل إزاي؟
Token Overlap	تقارن الكلمات المشتركة بين الإجابتين
TF-IDF Word	تقارن أهمية الكلمات ومجموعات الكلمات
TF-IDF Char	تقارن أنماط الحروف
SBERT MiniLM	تقارن المعنى العام للإجابتين
MiniLM + NLI	تضيف فحص التناقضات للتشابه الدلالي
Rubric + SBERT	تفحص معايير التصحيح واحدًا واحدًا بالتشابه الدلالي
Rubric + NLI	تفحص هل إجابة الطالب تستلزم تحقق كل معيار باستخدام NLI

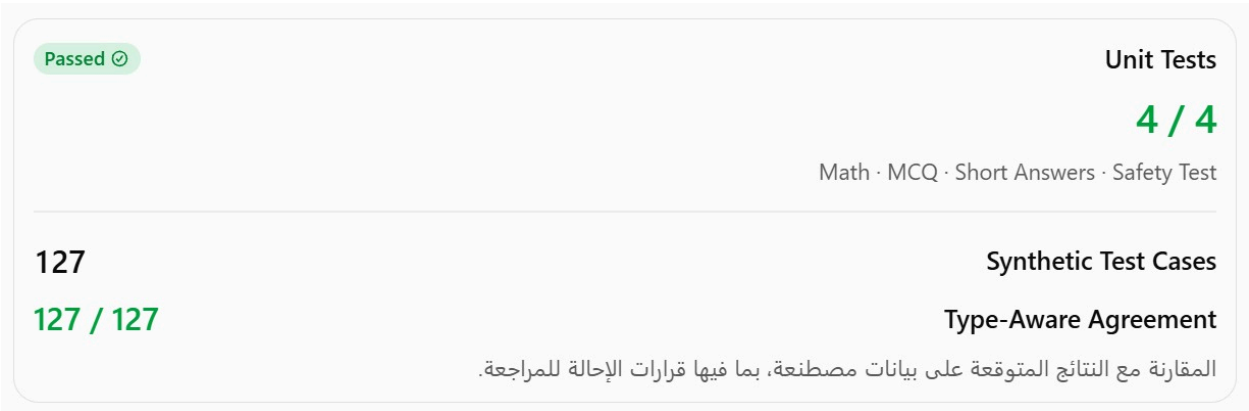
- No fine-tuning: إحنا استخدمنا موديلات جاهزة، مش دربناها أو عدلنا أوزانها على بيانات مشروعنا.
- No student grades: الدرجات المرجعية من أمثلة مصطنعة، مش من تصحيح طلاب حقيقيين.
- Threshold not validated: حدود اتخاذ القرار اللي استخدمناها لسه مش مثبتة على بيانات مستقلة.
- review alerts 24/25: النظام طلب مراجعة 24 إجابة من أصل 25، وده عبء كبير على المعيد.
- Rubric/half-point mismatch: بعض الدرجات المرجعية فيها أنصاف درجات مثل 2.5، بينما الـRubric التجريبي بيجمع خمس معايير ثنائية، كل واحد 0 أو 1.

وده سبب إن آخر عمود كله مكتوب فيه Synthetic-only.

يعني التجربة تثبت إننا شغّلنا الطرق وقارنا سلوكها، لكنها لا تثبت إن Rubric + NLI هو أفضل موديل لتصحيح إجابات الطلاب الحقيقيين.
بدأنا بمقارنة 7 طرق لتصحيح الإجابات القصيرة، بداية من طرق التشابه النصي البسيطة، وصولًا إلى Semantic Similarity وNLI وRubric-Based Grading.

النتائج الأولية أظهرت إن Rubric + NLI حقق أقل MAE وأعلى QWK على الداتا التجريبية. لكن تحليل الأخطاء كشف مشاكل في فهم بعض الإجابات الصحيحة المعاد صياغتها، بالإضافة إلى ارتفاع عدد الحالات المحتاجة مراجعة بشرية.

بناءً على النتائج دي، اتجهنا لتصميم Framework يعتمد على معايير تصحيح واضحة، واستخراج الأدلة من إجابة الطالب، ومراجعة المعيد للحالات غير المؤكدة، مع الحاجة لاختبار نهائي على بيانات مصححة بشريًا.
إحنا بنستخدمه علشان نثبت إن اختيار طريقة التصحيح في TAFlow قائم على Testing وComparison وError Analysis، مش مجرد اختيار موديل مشهور.



2. مقارنة الـMethods

Type-Aware	Strict Matching	Question Type
100%	37.5%	MCQ
100%	41.1%	Short Answer
100%	51.6%	Math

